

Reporte de evidencia — Especialista en enfermedades emocionales

Evaluación de recuperación RAG y end-to-end (gemma4) · 2026-09-06

Resumen

0.865

Precisión e2e (52 preguntas)

0.903

Recall single (e2e)

1.000

Recall alias (e2e)

1.000

Precisión fuera de dominio

El sistema recupera con fusión híbrida (FAISS + bge-m3 denso y BM25 léxico con match normalizado de título/alias) y responde con `gemma4` local, citando las fuentes usadas e integrando plantillas de seguridad médica resueltas en el backend.

1. Método

Gold set de **80 consultas coloquiales** (`eval/gold_set.json`) validadas contra el corpus de 1.265 términos. Para el eval end-to-end se derivaron **52 preguntas** (`eval/questions.json` : 31 single, 15 alias, 6 multi) y se corrieron por el pipeline completo del chat (`run_deterministic` → `gemma4`).

La verificación es **determinista**: la respuesta acierta si cita (slug en `sources[]`) o contiene el término esperado. Las métricas (media/mediana/DE/IC95%) se obtienen por **bootstrap con seed fijo**, reproducible con `scripts/e2e.py` .

Decisiones basadas en datos (k / τ / peso de fusión)

- `k = 5` (default), fusionando RRF de denso + léxico.
- `$\tau$` = existencia de **match nominal de título/alias** normalizado (la «señal fiable» de un diccionario, FR-09), con *light stemming* (plurales + deverbales) y stopwords. El denso solo desempata el ranking.
- Peso reforzado del match léxico; resolución de alias (FR-08a) y citación intersectada (§9).

2. Recuperación (§13.0)

Tipo	Resultado	Meta	Estado
single	27/31	recall@5 ≥ 0.85	✓
alias	13/15	recall@5 ≥ 0.90	parcial
risk_tier	9/10	término en top-k (10/10)	parcial
multi	5/6	cada síntoma en top-k (6/6)	parcial
out_of_domain	13/13	precision = 1.0	✓
emergency	5/5	corta antes del LLM	✓

Reproducible con `python -m eval.retrieval --k 5`.

Nota (recall parcial): 8 casos de sinonimia coloquial (p. ej. *panza*→*estómago*, *dormir*→*insomnio*, *me cuesta respirar*→*disnea*) no están en `alias.es.json` y el denso no los discrimina («vocabulario emocional casi idéntico», FR-09). Se priorizó la **precisión fuera de dominio = 1.0** (un falso positivo es peor que un fallo de recall).

3. Evaluación end-to-end (gemma4)

Métrica	n	media	mediana	DE	IC95% (bootstrap)
Precisión global (e2e)	52	0.865	1.000	0.341	[0.769, 0.942]
Recall single	31	0.903	1.000	0.296	[0.806, 1.000]
Recall alias	15	1.000	1.000	0.000	[1.000, 1.000]
Recall multi	6	0.333	0.000	0.471	[0.000, 0.667]

Bootstrap con seed=42 y 2000 remuestreos. Latencia por turno (gemma4 local, Ollama): single: media 8.46s / mediana 7.18s · alias: media 10.57s / mediana 10.04s · multi: media 9.68s / mediana 9.97s.

Aciertos consistentes con las metas: recall single $0.903 \geq 0.85$ y alias $1.000 \geq 0.90$.

Multi-hop (recall 0.333): relacionar y citar TODOS los síntomas en una síntesis cohesiva es el caso más difícil del modelo local; además arrastra el hueco de sinonimia (*pelo*→*alopecia*). El camino multi-hop determinista (extraer → N búsquedas → 1 síntesis) funciona; la limitación está en la fidelidad de citación de todos los términos.

4. Guardarraíles de seguridad médica

- **FR-05a (derivación por riesgo):** 156 términos en 7 niveles elevados → plantilla de derivación resuelta en backend (no por prompt). Verificado parametrizado sobre los 156.
- **FR-05b (lenguaje causal):** 0 patrones causales en plantillas y respuestas (asociativo, nunca causal).
- **FR-06 (emergencias):** 6 grupos en `rag/emergency_patterns.json` cortan ANTES de recuperar (assert de no-recuperación); NFR-02b (mecanismo, no instrucción).
- **NFR-01:** prompt-injection → 403 + audit_log; guardarraíles extendidos al dominio (prescripción/diagnóstico forzado).

5. Riesgos y mitigaciones (§14)

- **Sinonimia coloquial fuera de `aliases.json`** : degrada recall en multi y un subconjunto de single. Mitigación adoptada: precisión 1.0 fuera de dominio; pendiente una expansión de sinónimos curados si se quiere cerrar el recall.
- **gemma4 es un modelo «thinking» y no honra el rol `system`** : sin `think:false` devuelve `content=''`. Mitigación: llamada nativa a `/api/chat` con `think:false` y reintentos.
- **Tool-calling iterativo poco fiable**: se evita por diseño (multi-hop determinista, §9).
- **Datos de salud (NFR-07)**: historial borrable por el usuario (FR-14b), sin logging de chats.


6. Escenarios end-to-end sobre la UI final

Cinco recorridos completos sobre la app en contenedor, capturados con Chrome headless (CDP) contra un usuario **registrado durante la propia corrida**. Cada escenario lleva una aserción: si los chips no se ven, si la respuesta de emergencia no se marca o si la inyección no se bloquea, la captura **falla** y no se genera evidencia.


GIF	FR/NFR	Qué demuestra	Captura
<code>registro.gif</code>	FR-16 / FR-18	Alta de usuario y entrada al chat	25 frames
<code>consulta.gif</code>	FR-03 / FR-19	Respuesta con chips de fuentes	22 frames
<code>emergencia.gif</code>	FR-06	Derivación determinista, sin LLM	23 frames
<code>seguridad.gif</code>	NFR-01	Prompt injection bloqueado	23 frames
<code>memoria.gif</code>	FR-13 / FR-14	Historial persistido y consultable	30 frames

Usuario registrado durante la corrida: `evidencia-83308086@demo.co`. Los GIFs animados están en `outputs/gifs/` y embebidos en `docs/QA_report.md` (un PDF no los anima).

7. Evidencia generada




Acceso — alta de usuario (FR-16)




Disclaimer visible antes del primer mensaje (FR-20)




Respuesta con chips de fuentes (FR-03/FR-19)



Emergencia — derivación sin pasar por el LLM (FR-06)



Prompt injection bloqueado con 403 (NFR-01)



El agente responde desde el historial (FR-13)



Historial persistido del portador (FR-14)



Sesiones ADK persistidas (FR-12)